



Facultad de Ciencias Económicas
Universidad de Buenos Aires




Diseño y gestión de base de Datos

UT 5: Las bases de datos orientadas a la analítica y los ETL



Esquema de la clase




Transaccionales vs Analíticas




El Data warehouse en el Business Intelligence



Tipo de información



Los tres problemas del OLTP



PROBLEMAS CON LOS DATOS

1. Información no integrada.
2. Inadecuados tiempos de respuesta.
3. Dificultad para construir la información

Necesidades de información


Integral
Externa e interna

Integral
Agregada

Ad hoc
Ocasional
Agregada
Permita estimar
el largo plazo

Realidad de los datos OLTP

1. INFORMACION NO INTEGRADA



Los tres problemas del OLTP

2. INADECUADOS TIEMPOS DE RESPUESTA



1. Compiten por los recursos: Transacciones y consultas OLAP
2. Interfieren bloqueos y otras técnicas que aseguran la consistencia.
3. Limitaciones para aplicar redundancia, índices especiales y otros criterios

Los tres problemas del OLTP

3. INEXISTENCIA DE HERRAMIENTAS

Niveles
Tácticos y
Estratégico



Consultas ad – hoc “amigables”
Información relevante

Acceso unificado y
certificado


Destacar alertas
tempranas

Compara con
datos del
contexto


```
SELECT COUNT(DISTINCT VENTA.Numero_factura) AS CANTIDAD_VENTAS,  
SUM(ITEM_VENTA.Cantidad_vendida * ITEM_VENTA.Precio_unitario) AS  
IMPORTE, CLIENTE.zona AS ZONA,  
YEAR(VENTA.fecha_venta) AS ANIO  
FROM VENTA INNER JOIN ITEM_VENTA  
ON VENTA.Numero_factura = ITEM_VENTA.Numero_factura INNER JOIN  
CLIENTE ON VENTA.Codigo_cliente = CLIENTE.Codigo_cliente  
GROUP BY CLIENTE.zona, YEAR(VENTA.fecha_venta)  
HAVING YEAR(VENTA.fecha_venta) in (2008, 2009, 2010, 2011, 2012)  
ORDER BY YEAR(VENTA.fecha_venta), CLIENTE.zona
```

Ventas

La solución a los problemas



Arquitectura del Business Intelligence



OLTP y OLAP

Data warehouse

Data mart

OLAP vs OLTP

Procesamiento

Bases de datos

Herramienta de
análisis multidimensional

OLTP


- Objetivo: Ejecutar y registrar operaciones diarias
- Tipo de datos: actuales, detallados, modificables
- Volumen de consulta: miles de operaciones cortas y rápidas (lectura/escritura)
- Estructura: Normalizada
- Usuario típico: clientes, empleados, proveedores (usuarios finales)

OLAP

- Objetivo: Analizar datos históricos y tendencias
- Tipo de datos: históricos, consolidados y de solo lectura
- Volumen de consulta: consultas complejas que leen millones de filas a la vez
- Estructura: desnormalizada o multidimensional
- Usuario típico: analistas de datos, gerentes o directivos

El Data warehouse


1. Integra datos de los distintos sistemas OLTP.
2. Incorpora datos externos.
3. Incorpora datos históricos que no existan en los sistemas OLTP (por ventana operacional y/o update de datos).
4. Diseñado con foco en el aprovechamiento de los datos (temáticas de información)
5. Se actualiza solo mediante inserciones (no se modifican los datos).
6. El diseño y administración para un procesamiento OLAP eficiente:
 - Guardar datos pre calculados.
 - Índices que optimicen este tipo de consultas.
 - Estructuras de datos redundantes,
 - Independizar las bases de datos de la alta concurrencia del OLTP.
 - Datos columnares, estructuras en memoria, etc.




El Data warehouse y la redundancia

Propiedad	Efectos	
	Base OLTP	Data warehouse
Acelerar consultas con datos precalculados	✓	✓
Mayor tiempo en actualización de datos	✗	✗
Mayor probabilidad de generar inconsistencias	✗	✗
Espacio de almacenamiento	✗	✗

Integrar datos de distintos sistemas OLTP




Datos históricos




Ej: Caso Jurassic Park

Realidad de datos



Consigna:

- Identifiquen una decisión, que bajo la realidad de datos de este caso, que permita evidenciar al menos dos de los tres problemas del OLTP vistos.
- Describan porqué entienden que tienen esos problemas para la decisión planteada.
- Expliquen de que forma una solución que incluya un Data warehouse podría solucionar dichos problemas.





Visualizaciones




El Modelado dimensional

Un **modelo de datos** especialmente diseñado para su exploración desde los hechos y dimensiones que interesan al **"negocio"**.




- Modelo estrella

Tabla de hechos



- Es donde se guardan los **hechos** y sus medidas numéricas del negocio.
 - Aditivas,
 - semi aditivas
 - no aditivas.
- Tiene definida una **granularidad**: Es cada fila. Dada por las dimensiones por las que se podrá explorar las medidas.
- Tiene un **FK** a la clave primaria (PK) de cada tabla de dimensión.
- **Gran cantidad de filas**. Se trata de minimizar el tamaño de cada fila (pocos atributos y tipos de datos de poca longitud: integer para FK – claves subrogadas).

Tablas de Dimension



- Son las tablas donde se describen **cualitativamente** los procesos del negocio. El **contexto** desde el cual se analizan los hechos.
- Los **atributos** son los que permiten explorar los hechos. Con los atributos se arman las **jerarquías** de exploración.
- Se busca que tengan **gran cantidad de atributos**: cuanto más existan mayor la posibilidad de explorar las medidas desde distintas perspectivas de información.
- Uso de **claves subrogadas como PK**.

Ej: Caso Jurassic Park

The screenshot displays the Microsoft Power BI Desktop interface. The main workspace shows a data model with the following tables and their relationships:

- TD_Tiempo**: Contains fields: año, Fecha, id_tiempo, mes, semestre, trimestre. It is connected to **TH_Venta** via the **id_tiempo** field.
- TD_escuela**: Contains fields: Codigo_escuela, Id_escuela, Nombre_escuela, Tamaño, Tipo_escuela. It is connected to **TH_Venta** via the **Id_escuela** field.
- TD_Local**: Contains fields: Descripción, id_local, id_Parque. It is connected to **TH_Venta** via the **id_local** field.
- TH_Venta**: Contains fields: Codigo_entrada, costo_directo, Id_escuela, Id_local, Id_producto, id_tiempo, Importe_venta, Numero_ticket, Cantidad_ventas, Ganancia Bruta. It is the central fact table.
- TD_Producto**: Contains fields: Categoría, Descripción, Id_producto, Servicio_o_producto, Subcategoría. It is connected to **TH_Venta** via the **Id_producto** field.


On the left sidebar, there are two reports visible:

- Importe Ventas por tipo**: A pie chart showing the distribution of sales by type. The 'Servicio' category represents 20.49% of the total.
- Top 5 Locales según**: A list of the top 5 sales locations.


On the right sidebar, the 'Visualizaciones' pane shows various chart types available for the selected data. The 'Datos' pane shows the data fields for the selected table.

The bottom status bar indicates 'Página 1 de 1' and 'Ventas'.

Los procesos de ETL



T: Problemáticas en la integración de datos



T: Problemáticas en la integración de datos

- ✓ Identificar códigos divergentes para valores equivalentes (equivalencia de claves).




Sistema adquisiciones	Sistema ventas
Tabla: COMPRA	Tabla VENTA
Codigo_producto = 505244	Id_prod = R00256
Remera manga corta Modelo J&S	

- ✓ Unificar formatos, unidades de medida, internacionalización (monedas, horarios, etc.)

Sistema Logística SUC X	Sistema Logística SUC Y
Tabla: PRODUCTOS	Tabla Prod
Stock = 500 Pack	Stock = 800 u

Ej: Caso Jurassic Park


Realidad de datos



Visualizaciones


Consigna:
Ejemplifiquen un problema de integración y uno de limpieza de datos que debería resolver el ETL

Problemas de la ciencia de datos con el DW



Diferencias del “Data Lake” respecto del Data warehouse

1. Se almacenan todos los datos posibles




Almacenamiento de datos estructurados, semi y estructurados

Tecnologías para gestionar **grandes volúmenes de datos**

2. Raw data: los datos se almacenan en su forma original

E.L.T



3. Otro tipo de usuarios




4. Mayor agilidad en el delivery

Mayor flexibilidad para cambios y sin costos de integración.


5. No tiene foco en la integración

Falta de integración. Mayor dificultad en su gobernanza

Data Lake: repositorio vs entorno analítico



El data lake en la analítica de datos



Data Mesh

Zhamak Dehghani (2019)

El problema (Centralización)



- DW
- DL

Organizaciones basadas en datos

1. Falta de **agilidad** y **escalabilidad** de arquitecturas **centralizadas**.
2. Las **áreas centralizadas** tampoco entienden cómo **aprovechar los datos**

Gobernanza federada

Arquitectura + organización del trabajo (en relación a los datos).

Infraestructura de datos como
plataforma de autoservicio



Descentralización de equipos de trabajo
(científicos de datos, ingenieros de datos, etc.)

Un equipo de trabajo por **dominio** que entregan **productos de datos**.

Consumidores
de datos

los datos de origen

Los que mejor
entienden

productos de datos

Descubren


Los usan para:

- Toma de decisiones
- Iniciativas de negocio



Catálogo de productos

Minería de datos (Data Mining) y Analytics



- Monto y cantidad de Incobrables o de morosos para el año próximo.
- Ventas para el próximo año.
- Clientes que responderán afirmativamente a una campaña de marketing.
- Porcentaje de cancelaciones.

- Análisis de canasta de compra por tipo de cliente.
- Segmentación de clientes.
- Segmentación de empleados.



Conceptos relacionados

